

Facial Emotion Recognition

using Convolutional Neural Network (CNN)

จัดทำโดย

1.นางสาวนภัสสันท์ ดา咩พร รหัสบัตร 6610502102

2.นายสรล สังข์วงศ์ รหัสบัตร 6610505594

เสนอ

พศ.ดร.ภาครุจ รัตนวรพันธุ์

รายงานฉบับนี้เป็นส่วนหนึ่งของรายวิชา

การเรียนรู้เชิงลึก (Deep Learning) 01204466-65

ภาคเรียนที่ 1 ปีการศึกษา 2568

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตบางเขน

1. หัวข้อนี้นำเสนอใจอย่างไร ทำไมถึงเลือกหัวข้อนี้

ความนำเสนอใจของหัวข้อ Facial Emotion Recognition เกิดจากการที่ “อารมณ์” เป็นส่วนสำคัญของการสื่อสารระหว่างมนุษย์ และมีผลโดยตรงต่อพฤติกรรมและการตัดสินใจในสถานการณ์ต่าง ๆ หากคอมพิวเตอร์สามารถจดจำอารมณ์ของผู้ใช้งานได้ ก็จะช่วยให้ระบบสามารถโต้ตอบได้อย่างเหมาะสมและมีประสิทธิภาพมากขึ้น ซึ่งสอดคล้องกับแนวคิดของ Human-Computer Interaction ที่กำลังได้รับความสนใจอย่างกว้างขวางในปัจจุบัน

อีกทั้งการจำแนกอาการมณฑ์จากใบหน้ายังเป็นปัญหาที่ก้าวหาย เมื่องจากลักษณะใบหน้าของคนแต่ละคนแตกต่างกัน รวมถึงมีตัวแปรอื่น ๆ เช่น แสง มุมกล้อง และความเข้มของอารมณ์ ทำให้เป็นปัญหาที่เหมาะสมกับการประยุกต์ใช้เทคโนโลยี Deep Learning เพื่อช่วยในการเรียนรู้ลักษณะรูปแบบเชิงภาพที่ซับซ้อน

เหตุผลที่เลือกหัวข้อนี้

1. ความก้าวหน้าเชิงเทคโนโลยี

การจำแนกอาการมณฑ์เป็นปัญหาที่ต้องวิเคราะห์รายละเอียดของสีหน้าในระดับเล็กมาก เช่น การขยับคิ้ว ดวงตา หรือรูปปาก ซึ่งมีความแตกต่างกันเพียงเล็กน้อยระหว่างอารมณ์

2. ความเป็นไปได้ในการประยุกต์ใช้งานจริง

ระบบนี้สามารถนำไปใช้งานได้ในหลายด้าน เช่น

- ระบบช่วยการเรียนรู้ที่ปรับเนื้อหาตามอารมณ์ผู้เรียน
- ระบบบริการลูกค้าหรือ Call Center ที่ตอบสนองผู้ใช้ตามอารมณ์
- การติดตามสุขภาพจิต เช่น ผู้ป่วยซึมเศร้า

2. ทำไมหัวข้อนี้จึงต้องใช้ Deep Learning

การจำแนกอารมณ์จากใบหน้าเป็นปัญหาที่มีความซับซ้อนสูง เนื่องจากลักษณะของอารมณ์ไม่ได้ถูกกำหนดจากเพียงคำแห่งของอวัยวะบนใบหน้าเท่านั้น แต่ยังรวมถึงความเข้มของการแสดงออก มุ่งมอง และสีผิว และความแตกต่างเฉพาะบุคคล ทำให้การใช้วิธีการดึงเดิมในการดึงลักษณะเด่น (Feature Engineering) เช่น HOG, LBP หรือ SVM มีข้อจำกัด และมักให้ผลลัพธ์ไม่สม่ำเสมอเมื่อสภาพแวดล้อมเปลี่ยนแปลงไป

ในขณะที่ Deep Learning โดยเฉพาะ Convolutional Neural Network (CNN) สามารถเรียนรู้รูปแบบของภาพได้โดยอัตโนมัติ โดยไม่ต้องอาศัยการออกแบบคุณลักษณะด้วยมือ จึงเหมาะสมอย่างยิ่งสำหรับปัญหาด้าน Image Recognition และ Facial Expression Analysis และเหตุผลที่ต้องใช้ Deep learning ได้แก่

1. ลักษณะของปัญหาเป็นแบบเชิงภาพ (Image-based Problem)

อารมณ์ถูกสื่อสารผ่านการเปลี่ยนแปลงเชิงพื้นที่ของใบหน้า เช่น การยิ้ม การบ่น คิ้ว การหางตา ซึ่งเป็นข้อบุลประเทกภาพ CNN ถูกออกแบบมาเพื่อเรียนรู้ลักษณะเชิงพื้นที่โดยตรง จึงตอบโจทย์ปัญหานี้ได้ดีกว่าวิธี Machine Learning แบบดึงเดิม

2. CNN สามารถเรียนรู้ Feature กับซับซ้อนได้โดยอัตโนมัติ

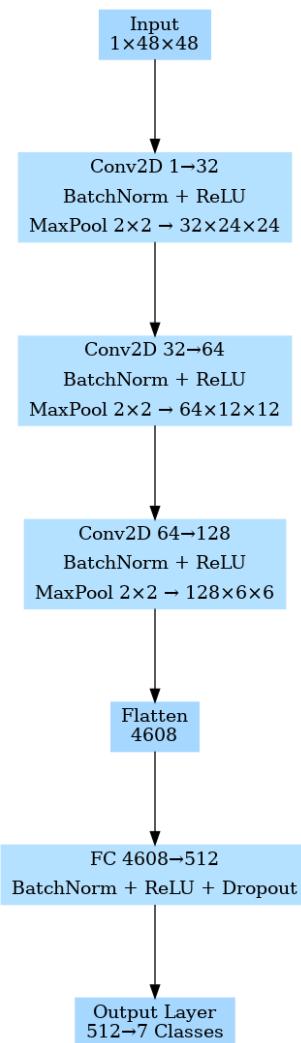
แทนที่มนุษย์จะต้องออกแบบ Feature เอง (ซึ่งอาจไม่ครอบคลุม), CNN สามารถเรียนรู้ตั้งแต่โครงสร้างพื้นฐาน (เช่น ขอบและเส้น) ไปจนถึงลักษณะใบหน้าที่ยากและมีความหมาย (เช่น ความตึงของกล้ามเนื้อรอบปากหรือดวงตา)

3. มีความยืดหยุ่นและประสิทธิภาพสูงกว่า Traditional ML

วิธีแบบ SVM, k-NN, หรือ Random Forest ต้องพึ่ง Feature Extraction ก่อนเสมอ และประสิทธิภาพจะขึ้นกับวิธีออกแบบ Feature ในขณะที่ CNN เรียนรู้กันหมดในขั้นตอนเดียว ทำให้ได้ผลลัพธ์ที่มีเสถียรภาพและแม่นยำมากกว่า

3. สถาปัตยกรรมของโมเดล (Model Architecture)

โมเดลที่ใช้ในโครงงานนี้เป็นโมเดลประเพณี Convolutional Neural Network (CNN) ซึ่งหมายความว่าโมเดลจะรับภาพเป็น input และมุ่งเน้นการเรียนรู้ลักษณะเชิงพื้นที่ของภาพ (Spatial Features) ได้โดยอัตโนมัติ โมเดลถูกออกแบบให้มีโครงสร้างแบบเรียงลำดับจากการดึงลักษณะก้าวไปของภาพไปจนถึงลักษณะเชิงอารมณ์ที่ละเอียดขึ้น ก่อนจะเชื่อมเข้าสู่ชั้น Fully Connected เพื่อกำหนายผลลัพธ์ในรูปแบบของคลาสอารมณ์ 7 ประเพณี ได้แก่ Angry, Disgust, Fear, Happy, Sad, Surprise และ Neutral ดังแสดงในภาพด้านล่างนี้



โครงสร้างของโมเดลประ愼คอบด้วย

ชั้น (Layer)	รายละเอียด	ขนาดเอาต์พุต
Input Layer	ภาพขาวดำขนาด 48×48 พิกเซล (1 ช่องสัญญาณ)	$1 \times 48 \times 48$
Convolution Block 1	Conv2D $1 \rightarrow 32$ + BatchNorm + ReLU + MaxPool(2×2)	$32 \times 24 \times 24$
Convolution Block 2	Conv2D $32 \rightarrow 64$ + BatchNorm + ReLU + MaxPool(2×2)	$64 \times 12 \times 12$
Convolution Block 3	Conv2D $64 \rightarrow 128$ + BatchNorm + ReLU + MaxPool(2×2)	$128 \times 6 \times 6$
Flatten Layer	แปลงข้อมูล 3 มิติให้เป็นเวกเตอร์ 1 มิติ	4608 nodes
Fully Connected Layer	Linear $4608 \rightarrow 512$ + BatchNorm + ReLU + Dropout	512
Output Layer	Linear $512 \rightarrow 7$ (จำนวนอารมณ์ทั้งหมด)	7 Classes

คำอธิบายหลักการทำงาน

1. Convolution Layers

ทำหน้าที่ดึงลักษณะพื้นฐานของภาพ เช่น เส้น ขอบ รูปร่างเบื้องต้น ก่อนจะค่อยๆ เรียนรู้ลักษณะที่เฉพาะเจาะจงของอารมณ์มากขึ้นเมื่อชั้นมีจำนวนพิจารณามากขึ้น

2. Batch Normalization

ช่วยให้การเรียนรู้มีความเสถียร ลดการกระจายของค่า Activation และช่วยให้ไม่เดลเทrnได้ไวขึ้น

3. ReLU Activation Function

ช่วยให้ไม่เดลสามารถเรียนรู้ความสัมพันธ์แบบไม่เชิงเส้น ซึ่งสำคัญในการจำแนกอารมณ์ที่มีความแตกต่างละเอียด

4. MaxPooling Layers

ลดขนาดข้อมูลลง แต่คงข้อมูลลักษณะเด่น ทำให้ไม่เดลประยัดหน่วยความจำและลดโอกาส Overfitting

5. Fully Connected Layer + Dropout

เชื่อมข้อมูลที่สกัดแล้วไปยังขั้นตอนการจำแนก พร้อม Dropout ช่วยป้องกันการจำค่ามากเกินไป

6. Output Layer

นำนายผลลัพธ์เป็นหนึ่งใน 7 คลาสอารมณ์ตามค่าความบ่าจะเป็นที่ไม่เดลเรียนรู้

4. อธิบายโค้ดและโครงสร้างระบบ

โครงงานนี้ใช้ PyTorch เป็น Framework หลักในการสร้างและฝึกสอนโมเดล Convolutional Neural Network (CNN) สำหรับจำแนกอารมณ์จากใบหน้า โดยมีการทำงานแบ่งอุปกรณ์เป็นขั้นตอนดังนี้

ส่วนที่ 1: การนำเข้า Libraries และการตั้งค่าเบื้องต้น

- นำเข้า Libraries ที่จำเป็น เช่น torch, torch.nn, torchvision.transforms, numpy, pandas, matplotlib, seaborn, และ cv2
- ตรวจสอบและตั้งค่าอุปกรณ์ประมวลผล (Device) ให้รองรับ GPU หากมีการเชื่อมต่อ เพื่อเพิ่มความเร็วในการฝึกโมเดล

```
device = torch.device("cuda" if
torch.cuda.is_available() else "cpu")
```

ส่วนที่ 2: การจัดเตรียมและประมวลผลข้อมูล (Data Processing)

- ใช้ชุดข้อมูล FER2013 ซึ่งอยู่ในรูป .csv ประกอบด้วยคอลัมน์ emotion, pixels, และ Usage
- สร้างคลาส FER2013Dataset เพื่ออ่านข้อมูล, แปลง string ของ pixel เป็นภาพ 48×48 และกำหนด label (emotion)
- เตรียม Transform สำหรับการฝึกและทดสอบโมเดล
 - แปลงเป็นภาพ Grayscale
 - ปรับขนาดเป็น 48×48
 - Normalize ค่า pixel ให้อยู่ในช่วง (-1, 1)
- แบ่งข้อมูลเป็น 3 ส่วน ได้แก่ Training (Training), Validation (PublicTest) และ Testing (PrivateTest)
- ใช้ DataLoader ของ PyTorch เพื่อโหลดข้อมูลเป็น Batch ขนาด 64

ส่วนที่ 3: การสร้างโมเดล (Model Construction)

สร้างคลาส SimpleCNN_with_BatchNorm สืบทอดจาก nn.Module
โมเดลนี้ประกอบด้วย 3 Convolutional Blocks ตามลำดับ พร้อม Batch Normalization
และ Dropout

Layer	ขนาดอินพุต → เอาต์พุต	พารามิเตอร์	Activation Function
Conv1 + BN1 + Pool	$1 \times 48 \times 48 \rightarrow 32 \times 24 \times 24$	$(3 \times 3 \times 1 \times 32) + 32$	ReLU
Conv2 + BN2 + Pool	$32 \times 24 \times 24 \rightarrow 64 \times 12 \times 12$	$(3 \times 3 \times 32 \times 64) + 64$	ReLU
Conv3 + BN3 + Pool	$64 \times 12 \times 12 \rightarrow 128 \times 6 \times 6$	$(3 \times 3 \times 64 \times 128) + 128$	ReLU
Fully Connected	$4608 \rightarrow 512$	$(4608 \times 512) + 512$	ReLU + Dropout(0.5)
Output Layer	$512 \rightarrow 7$	$(512 \times 7) + 7$	Softmax

ส่วนที่ 4: การตั้งค่า Loss Function และ Optimizer

- Loss Function ที่ใช้: **Cross Entropy Loss**
- Optimizer ที่ใช้: **Adam Optimizer** (Learning rate = 0.001)

ส่วนที่ 5: ขั้นตอนการฝึกโมเดล (Training Process)

- ตั้งค่า Epoch = 50
- ใช้โค้ด `model.train()` เพื่อเปิด Dropout และ BatchNorm สำหรับการฝึก
- วนลูปฝึกโมเดล โดยคำนวณ Loss และอัปเดต Weight ด้วย Backpropagation
- หลังจบแต่ละ Epoch จะคำนวณ **Validation Loss และ Accuracy**
และเก็บไว้ใน list `train_losses, val_losses, val_accuracies`
- เมื่อการฝึกจบลง จะบันทึกน้ำหนักโมเดลลงไฟล์
`fer2013_cnn_model_with_evaluate.pth`

ส่วนที่ 6: การประเมินผล (Model Evaluation)

ในขั้นตอนนี้จะใช้ชุดข้อมูลทดสอบเพื่อวัดประสิทธิภาพของโมเดล

โดยใช้ Metrics ได้แก่ Accuracy, Precision, Recall, F1-score และ Confusion Matrix
พร้อมกับพื้นอตกราฟ Training/Validation Loss และ Accuracy ต่อ Epoch เพื่อแสดง
แนวโน้มการเรียนรู้ของโมเดล

ส่วนที่ 7: การเชื่อมต่อกับโมเดลและการใช้งานจริง (Real-Time Inference)

ไฟล์: `test_optimized.py`

- โหลดโมเดลที่ฝึกแล้ว (`.pth`)
- ใช้ OpenCV Haar Cascade ตรวจจับใบหน้าผ่านกล้องเว็บแคม
- ตัดภาพใบหน้า → ปรับขนาดเป็น 48×48 → แปลงเป็น Tensor
- ส่งภาพเข้าสู่โมเดลเพื่อคำนวณอารมณ์
- แสดงผลลัพธ์เป็นชื่ออารมณ์บนภาพแบบเรียลไทม์

5. อธิบาย Dataset ที่ใช้ และวิธีในการ Train

Dataset ที่ใช้

- ชื่อชุดข้อมูล: FER2013 (Facial Expression Recognition 2013)

แหล่งที่มา: Kaggle

<https://www.kaggle.com/code/gauravsharma99/facial-emotion-recognition>

- รูปแบบข้อมูล:

- บันทึกเป็น .csv โดยมีคอลัมน์หลักคือ
 - emotion → label ของอารมณ์ (0–6)
 - pixels → ค่าพิกเซลของภาพใบหน้าขนาด 48×48
 - Usage → ประเภทของข้อมูล (Training, PublicTest, PrivateTest)

Emotion Label	Emotion Name
0	Angry
1	Disgust
2	Fear
3	Happy
4	Sad
5	Surprise

6	Neutral
---	---------

- **จำนวนภาพทั้งหมด:** 35,887 ภาพ
- **รูปแบบภาพ:** Grayscale (1 channel), ขนาด 48×48 pixels
- **การแบ่งข้อมูล:**
 - Training set: 28,709 ภาพ
 - Validation set (PublicTest): 3,589 ภาพ
 - Test set (PrivateTest): 3,589 ภาพ

อธิบายโค้ดส่วนที่ใช้ Train

```

import torch.optim as optim
import torch.nn as nn
# --- (สมมติว่า model, train_loader, test_loader, device อยู่ตรงนี้แล้ว) ---
model = SimpleCNN_with_BatchNorm().to(device) # (จากโค้ดก่อนหน้า)
train_loader # (จากโค้ดก่อนหน้า)
test_loader # (จากโค้ดก่อนหน้า)
device # (จากโค้ดก่อนหน้า)
# -----
# กำหนด Loss and Optimizer
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=0.001)

# --- อุปการะณ์ ---
num_epochs = 50

# (เพื่อเก็บ history ไว้พิจารณา)
train_losses = []
val_losses = []

```

```

val_accuracies = []

for epoch in range(num_epochs):

    # =====
    # TRAINING LOOP
    # =====
    model.train() # ตั้งค่าเป็น training mode
    running_loss = 0.0

    for images, labels in train_loader:
        images, labels = images.to(device), labels.to(device)
        optimizer.zero_grad()
        outputs = model(images)
        loss = criterion(outputs, labels)
        loss.backward()
        optimizer.step()
        running_loss += loss.item() * images.size(0)

    epoch_loss = running_loss / len(train_dataset)
    train_losses.append(epoch_loss)

    # =====
    # VALIDATION LOOP <--- (ส่วนที่เพิ่มเข้ามา)
    # =====
    model.eval() # <--- สำคัญมาก! ตั้งค่าเป็น evaluation mode (ปิด Dropout, BatchNorm)
    val_running_loss = 0.0
    correct_preds = 0
    total_preds = 0

    with torch.no_grad(): # <--- สำคัญมาก! ไม่ต้องคำนวณ gradient ตอน tes
        for images, labels in test_loader:
            images, labels = images.to(device), labels.to(device)

            # Forward pass

```

```

outputs = model(images)

# Calculate loss
loss = criterion(outputs, labels)
val_running_loss += loss.item() * images.size(0)

# Calculate accuracy
# torch.max จะคืนค่า (max_value, max_index)
_, predicted_labels = torch.max(outputs, 1)

total_preds += labels.size(0)
correct_preds += (predicted_labels == labels).sum().item()

# คำนวณ Loss และ Accuracy ของ Validation set
epoch_val_loss = val_running_loss / len(test_dataset)
epoch_val_acc = (correct_preds / total_preds) * 100

val_losses.append(epoch_val_loss)
val_accuracies.append(epoch_val_acc)

# พิมพ์ผลลัพธ์ของ Epoch นี้
print(f"Epoch [{epoch+1}/{num_epochs}], "
      f"Train Loss: {epoch_loss:.4f}, "
      f"Val Loss: {epoch_val_loss:.4f}, "
      f"Val Acc: {epoch_val_acc:.2f}%")

print("Training Finished!")

# บันทึกโมเดล
torch.save(model.state_dict(), 'fer2013_cnn_model_with_evaluate.pth') # (ผูกเก้าอี้ไฟล์เล็ก
น้อย)
print("Model Saved!")

```

1. การวางแผนสร้าง Training (Training Loop)

- ลูปการเทรนทั้งหมดมี 50 epochs
- แต่ละ epoch แบ่งการทำงานเป็น 2 ขั้นตอนหลัก
 - Training Phase → ให้โมเดลเรียนรู้จากข้อมูลฝึก
 - Validation Phase → ทดสอบความแม่นยำกับข้อมูลทดสอบ

2. Training Phase

ตั้งค่าโมเดลให้อยู่ในโหมด training ด้วยคำสั่ง `model.train()`

- เพื่อเปิดการทำงานของ BatchNorm และ Dropout
- วนลูปผ่านข้อมูลใน `train_loader` (batch size = 64)
- ในแต่ละ batch มีลำดับการทำงานดังนี้
 - Forward Pass:
 - ส่งข้อมูลภาพ (`images`) เข้าโมเดล → ได้ผลลัพธ์ `outputs`
 - Compute Loss:
 - คำนวณค่าความผิดพลาดระหว่าง `outputs` กับ `labels`
 - Backward Pass:
 - เคลียร์ค่า `gradient` เดิม
 - คำนวณ `gradient` ใหม่จาก `loss`
 - อัปเดตค่าหนักของโมเดล
- หลังจากประเมินผลครบถ้วน batch จะคำนวณ Train Loss เฉลี่ยของ epoch นั้น และบันทึกลงในตัวแปร `train_losses`

3. Validation Phase

- ตั้งค่าโมเดลเป็นโหมด evaluation เพื่อปิด Dropout และทำให้ BatchNorm ใช้ค่าเฉลี่ยคงที่
- ใช้ `torch.no_grad()` เพื่อปิดการคำนวณ gradient (ช่วยลดหน่วยความจำ)
- วนลูปผ่านข้อมูลใน `test_loader`
 - ทำการ Forward Pass เพื่อคำนวณผลลัพธ์
 - คำนวณค่า Validation Loss ด้วย `criterion(outputs, labels)`
 - นับจำนวนคำทำนายที่ถูกต้องเพื่อนำไปคำนวณ Accuracy (%)
- หลังจบแต่ละ epoch จะบันทึก
 - `val_losses` → ค่า Loss ของ validation
 - `val_accuracies` → ค่าความแม่นยำ (%) ของ validation

4. การแสดงผลระหว่างการเทรน

- หลังจบแต่ละ epoch จะพิมพ์ผลลัพธ์สรุปอุปกรณ์มาบนหน้าจอ เช่น Epoch [1/50], Train Loss: 1.8234, Val Loss: 1.5910, Val Acc: 44.52%
- เพื่อให้เห็นแนวโน้มว่าโมเดลเรียนรู้ดีขึ้นหรือไม่

5. การบันทึกโมเดล (Model Saving)

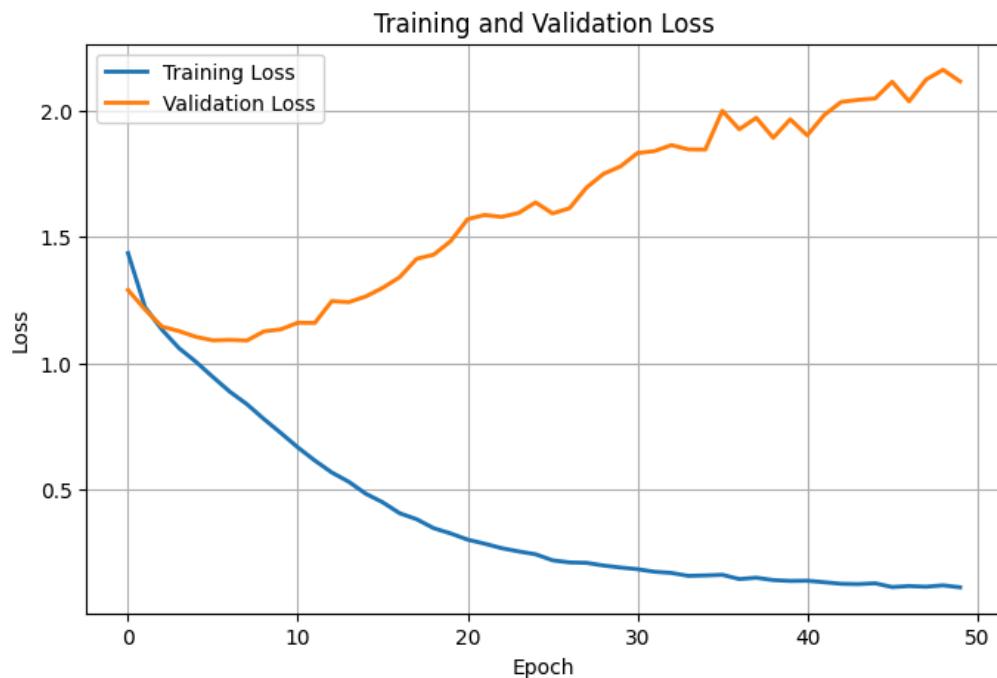
- เมื่อเทรนครบถ้วน epoch จะบันทึกน้ำหนักโมเดลลงในไฟล์ `torch.save(model.state_dict(),'fer2013_cnn_model_with_evaluate.pth')`
- ไฟล์นี้จะถูกนำไปใช้ในขั้นตอนคำนวณจริง (Real-Time Emotion Detection)

6. สรุปแบบการทำงานของโค้ด

- Forward Pass → โมเดลคำนวณผลลัพธ์จากภาพ
- Backward Pass → ปรับค่าน้ำหนักตามค่า Loss
- Evaluation → ตรวจสอบประสิทธิภาพบนชุดทดสอบ
- Saving → เก็บโมเดลที่เรียนรู้เสร็จแล้วไว้ใช้งานจริง

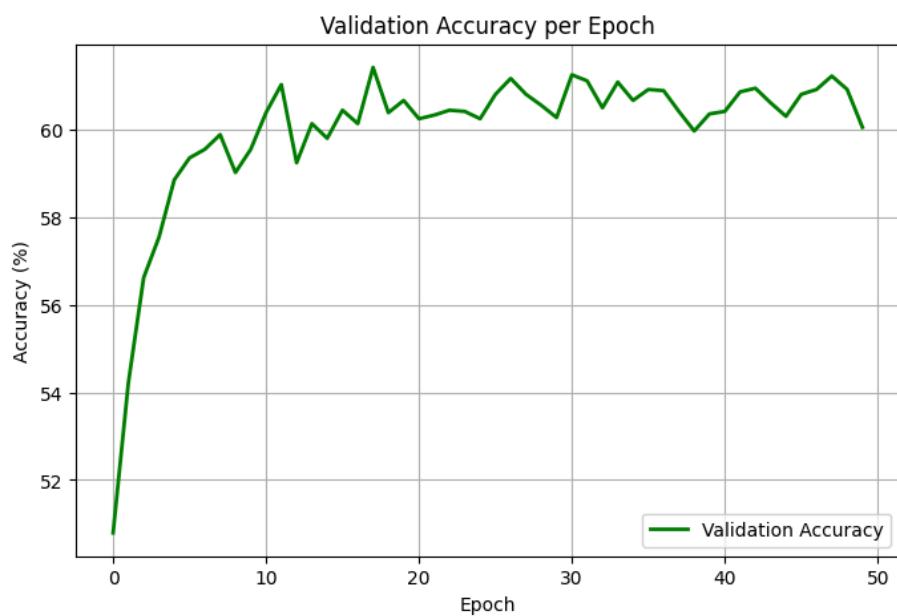
6. อธิบายการประเมิน (Evaluate Model)

1. การประเมินค่า Loss จากการเทรน



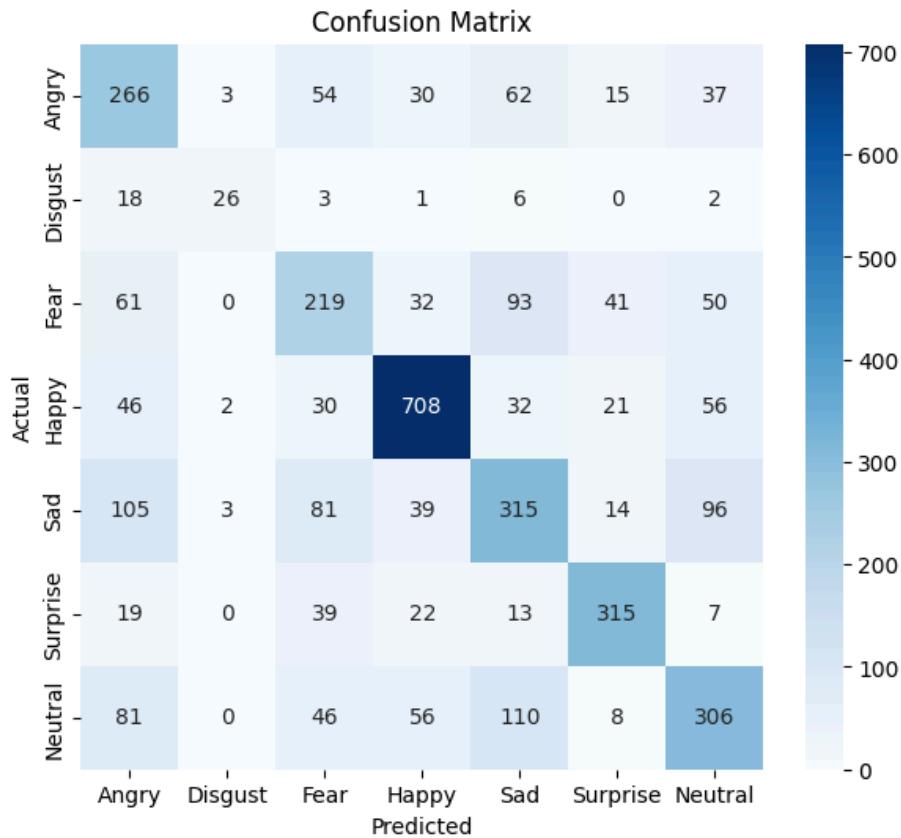
- ระหว่างการฝึก ได้เก็บค่าการเปลี่ยนแปลงของ Training Loss และ Validation Loss ไว้ในแต่ละ Epoch
- จากกราฟจะเห็นว่า
 - ค่า Training Loss ลดลงอย่างต่อเนื่อง และแสดงว่าโมเดลเรียนรู้จากข้อมูลฝึกได้ดี
 - ค่า Validation Loss มีแนวโน้มเพิ่มขึ้นหลัง Epoch ที่ ~20 บ่งบอกถึงการเริ่มเกิด Overfitting
- ค่า Loss ใช้ในการตรวจสอบว่าการเรียนรู้ของโมเดลมีเสถียรภาพหรือไม่ และช่วยกำหนดจุดที่เหมาะสมในการหยุดฝึก (Early Stopping)

2. การประเมินค่า Accuracy



- ใช้คำนวณจากสัดส่วนของจำนวนภาพที่ไม่เดลทำนายถูกต้องต่อจำนวนภาพทั้งหมด ในชุดทดสอบ
- ในการเทรนครั้งนี้ Accuracy ถูกคำนวณทุก Epoch และเก็บไว้ในตัวแปร `val_accuracies`
- จากราฟแสดงให้เห็นว่า Accuracy เพิ่มขึ้นรวดเร็วในช่วงต้น และคงที่อยู่ระหว่าง 60–62% หลังจาก Epoch ที่ 10 เป็นต้นไป
- แสดงว่าไม่เดลสามารถแยกแยะอารมณ์ได้ในระดับที่มีความถูกต้องพอสมควร สำหรับงานจำแนกภาพอารมณ์

3. การประเมินด้วย Confusion Matrix



- ใช้เพื่อแสดงการจำแนกผลลัพธ์จริงกับผลลัพธ์ที่ไม่เดลกหมาย
- ในแต่ละแควคือ “อารมณ์จริง” และแต่ละคอลัมนิคือ “อารมณ์ที่ไม่เดลกหมายได้”
- จาก Matrix พบร่วมกันที่ไม่เดลสามารถจำแนกอารมณ์ Happy, Neutral และ Surprise ได้ค่อนข้างดี (ค่าบนแนวทแยงสูง) แต่มีการสับสนระหว่าง Fear, Sad และ Angry ซึ่งมักมีลักษณะทางสีหน้าใกล้เคียงกัน

7. อธิบายบทความอ้างอิงและงานที่เกี่ยวข้อง

โครงงานนี้ได้แนวคิดและแนวทางการพัฒนาโมเดลมาจากการ “Facial Emotion Recognition” โดย Gaurav Sharma เพย์แพร์บันเว็บไซต์ Kaggle (<https://www.kaggle.com/code/gauravsharma99/facial-emotion-recognition>)

1. ข้อมูลจากบทความต้นฉบับ

- Dataset: FER2013 (Facial Expression Recognition 2013)
มีภาพขาวดำขนาด 48×48 พิกเซล จำนวน 35,887 ภาพ แบ่งเป็น 7 อารมณ์ ได้แก่ Angry, Disgust, Fear, Happy, Sad, Surprise และ Neutral
- สถาปัตยกรรมโมเดล:
ใช้ CNN แบบหลายชั้น (Conv2D → ReLU → MaxPooling → Dropout)
พร้อม Softmax Output Layer สำหรับจำแนกอารมณ์
- เทคนิคการฝึกโมเดล:
ใช้ Adam Optimizer กับ Categorical CrossEntropy Loss
และเพิ่ม Data Augmentation เช่น การพลิกภาพ (flip) และหมุน (rotation)
เพื่อเพิ่มความหลากหลายและลด Overfitting

2. แนวคิดที่นำมาประยุกต์ใช้ในโครงงานนี้

- นำแนวคิดสถาปัตยกรรม CNN หลักจากบทความต้นฉบับมาพัฒนาใหม่ให้เหมาะสมกับ PyTorch Framework
- เพิ่ม Batch Normalization ในแต่ละ Convolution Block เพื่อให้การเรียนรู้เสถียรขึ้น
- เพิ่มขั้นตอน Validation Phase และการเก็บค่า Loss / Accuracy ราย Epoch เพื่อใช้วัดระดับประสิทธิภาพของโมเดล
- ใช้หลักการเดียวกันในการตรวจสอบใบหน้าจริงผ่านกล้อง โดยใช้ไฟล์ haarcascade_frontalface_default.xml และโมเดลที่ฝึกจาก FER2013

3. ความเกี่ยวข้องกับงานวิจัยอื่น

- Kaggle Notebook ดังกล่าวต่อยอดแนวคิดจากงานของ Goodfellow et al. (2013) และ Tang (2013) ที่เปิดตัว FER2013 dataset และใช้ CNN เป็นสถาปัตยกรรมหลัก

8.ลิงค์ Github ไว้รับรวมโค้ด

https://github.com/Napatsanan-dmp/Project_deeplearning

9.แบ่งสัดส่วนการทำงาน

1.งานสาวนักศึกษา ตามะพร (50%)

- ศึกษาและรับรวมข้อมูลเกี่ยวกับ Facial Emotion Recognition และ FER2013 Dataset
- ออกแบบและสร้างสถาปัตยกรรมโมเดล CNN ใน PyTorch
- พัฒนา Notebook สำหรับการเทรนและประเมินผลโมเดล
- เขียนรายงานส่วนการอธิบายโมเดล, วิธีการเทรน

2.นายสรัล สังข์วงศ์ (50%)

- พัฒนาโค้ดส่วนการตรวจจับใบหน้าและเชื่อมต่อโมเดลกับกล้อง (test_optimized.py)
- ปรับแต่งการทำงานของโมเดลสำหรับการใช้งานแบบ Real-Time
- วิเคราะห์ผลการทำงานของโมเดลจากค่า Accuracy, Precision, Recall, และ F1-score
- เขียนรายงานส่วนการอธิบายการใช้งานจริง, การเชื่อมต่อระบบ, และการประเมินผล